

Sistema Integrado de Processamento de Linguagem Natural e Machine Learning para Tipificação Criminal e Decisão de Procedimento Policial

Integrantes da Equipe:

Bruno Sampaio Assis

Daniel Barrozo Lima

Micael Trindade

Pedro Henrique Casimiro

Pedro Guilherme Feitoza Melo

1. Introdução

Nome do Projeto:

Sistema Integrado de Processamento de Linguagem Natural e Machine Learning para Tipificação Criminal e Decisão de Procedimento Policial

Resumo do Projeto:

No contexto da atividade de polícia judiciária, a triagem e o enquadramento de ocorrências demandam análise minuciosa de relatos textuais e de circunstâncias fáticas para determinar a capitulação legal e a peça procedimental adequada. Este projeto propõe o desenvolvimento de um pipeline integrado de MLOps voltado a automatizar e apoiar a tomada de decisão policial em dois estágios decisórios sequenciais:

1. **Classificação da Natureza do Delito (NLP):** A partir das narrativas textuais dos fatos (relatos da vítima, do autor e histórico da ocorrência), modelos de Processamento de Linguagem Natural sugerem a tipificação criminal preliminar (como Roubo, Furto, Estelionato, Violência Doméstica, entre outras).
2. **Predição do Procedimento Policial (Classificação Multiclasse Tabular/Híbrida):** Combinando a tipificação predita com atributos circunstanciais (envolvimento de menor, gravidade da lesão, meio empregado, perícia e vínculo entre os envolvidos), o modelo prediz a peça jurídica cabível a ser instaurada de imediato (Auto de Prisão em Flagrante APF, Inquérito Policial IP, Termo Circunstanciado de Ocorrência TCO).

O projeto abrange desde o pré-processamento e engenharia de atributos até a esteira de experimentação, validação de métricas de desempenho (F1-score ponderado e acurácia) e empacotamento da solução, reduzindo o tempo de triagem manual e aumentando a padronização e consistência dos despachos preliminares na unidade policial.

2. Tema do Projeto

- **Tema Selecionado:** Automação de Triagem e Despacho Policial sobre Procedimento a Instaurar com aplicação de PLN e Modelos Preditivos Híbridos
- **Contexto e Motivação:** No cotidiano das delegacias de polícia, a triagem inicial de ocorrências impõe um volume elevado de decisões. A autoridade policial precisa analisar narrativas textuais (relatos de vítimas, autores e testemunhas) e confrontá-las com dados contextuais (envolvimento de menores, meios empregados, gravidade de lesões e existência de perícia) para determinar a capitulação penal preliminar e decidir a peça processual cabível — como a lavratura de Auto de Prisão em Flagrante (APF), instauração de Inquérito Policial (IP), lavratura de Termo Circunstanciado de Ocorrência (TCO). A relevância do projeto reside na redução do gargalo operacional e na mitigação de assimetrias ou inconsistências no enquadramento procedimental. Ao integrar Processamento de Linguagem Natural (PLN) para a interpretação dos depoimentos e modelos de Machine Learning para a classificação multiclasse do procedimento, o sistema atua como ferramenta de suporte à decisão, padronizando a triagem preliminar, acelerando o fluxo cartorário e permitindo que os operadores da segurança pública priorizem ocorrências de maior gravidade e complexidade investigativa.

3. Objetivos do Projeto

- **Objetivo Principal:** O que o modelo de Machine Learning vai prever exatamente (ex: *prever a tipificação penal da ocorrência, classificar a prioridade de atendimento, estimar tempo de resolução*).
- **Tipo de Problema de ML:** (Ex: Classificação Multiclasse, Classificação Binária, Regressão, NLP).
- **Objetivos Específicos:**
 - Tratar e explorar a base de dados histórica.
 - Treinar e validar modelos preditivos de referência (*baseline* vs. modelo final).
 - Estruturar o pipeline de entrega/inferência seguindo boas práticas de MLOps.

Objetivo Principal: Prever a tipificação penal da ocorrência a partir dos relatos textuais e classificar a peça jurídica adequada a ser instaurada pelo Delegado de Polícia (APF, IP, TCO).

Tipo de Problema de ML: Classificação Multiclasse e Processamento de Linguagem Natural (PLN / NLP) em abordagem híbrida (dados tabulares e textuais).

Objetivos Específicos:

- **Tratamento e Análise Exploratória:** Limpar, vetorizar os relatos fáticos (TF-IDF/Embeddings) e codificar variáveis circunstanciais (envolvimento de menor, meios empregados, gravidade da lesão).
- **Treinamento e Validação:** Desenvolver modelos de referência (*baseline*) e modelos finais comparando algoritmos clássicos e ensembles (ex.: Logistic Regression, Random Forest, XGBoost), avaliando por F1-Score ponderado e Acurácia.
- **Pipeline e MLOps:** Estruturar o fluxo ponta a ponta de pré-processamento, inferência, versionamento de artefatos e automação de deploy da solução.

4. Escopo do Projeto

O que está no escopo (O que o projeto VAI abranger):

- **Pré-processamento e Feature Engineering:** Limpeza da base histórica, vetorização textual dos depoimentos e codificação dos atributos circunstanciais.
- **Modelagem e Avaliação:** Treinamento, validação cruzada e comparação de métricas (*Acurácia, Precision, Recall, F1-Score*) entre modelos *baseline* e finais.
- **Práticas de MLOps:** Versionamento de código, controle de artefatos do modelo e esteira automatizada de CI/CD e infraestrutura (IaC).
- **Serviço de Inferência:** Desenvolvimento de API (ou interface demonstrativa interativa) para submissão de novos boletins e retorno das predições.

O que NÃO está no escopo (Limitações / O que NÃO vai abranger):

- **Conexão com Sistemas de Produção:** Integração direta com bancos de dados legados ou sistemas policiais em tempo real.
- **Outras Modalidades de Dados:** Suporte a arquivos não estruturados além de texto (como áudios de depoimentos, imagens de perícia ou vídeos).
- **Infraestrutura de Alta Disponibilidade:** Garantia de disponibilidade crítica, balanceamento de carga para alta concorrência ou SLA comercial.

○

5. Resultados Esperados

Métricas de Desempenho do Modelo:

- **F1-Score Ponderado:** $\geq 85\%$ nas previsões de natureza da ocorrência e procedimento gerado.
- **Acurácia Geral:** $\geq 85\%$ no conjunto de teste.
- **Matriz de Confusão e Recall:** Minimização de falsos negativos em classes críticas (como *APF* e crimes violentos).

Entregáveis Práticos:

- **Repositório Git Estruturado:** Código versionado, modular e documentado via [README.md](#).
- **Pipeline de MLOps/Automação:** Scripts de pré-processamento, rotinas de CI/CD e esteira para versionamento/deploy de artefatos.
- **Interface/API de Inferência:** Endpoint funcional para simular o envio de um novo BO e retornar as previsões.
- **Relatório Técnico:** Documento final consolidando a comparação entre *baseline* e modelo final, análises de erros e conclusões.

Impacto Operacional Esperado:

- **Agilidade no Plantão:** Redução substancial no tempo gasto na leitura e triagem manual preliminar dos boletins.
- **Padronização Decisória:** Minimização de divergências no enquadramento de procedimentos cabíveis.

- **Suporte à Decisão:** Apoio analítico ao Delegado de Polícia para priorização de casos graves e encaminhamentos assertivos.